

HAILA

Relatório técnico da amostra final de questões

Geração híbrida com RAG, LLM, SLM e red flags determinísticas

Finalidade

Apresentar aos orientadores a amostra de cinco questões geradas e sua avaliação, sem comparação entre versões do sistema.

Amostra: cinco itens objetivos de Computação, no formato ENADE.

Data do relatório: 24 de setembro de 2026.

Escopo: avaliação automática IWF/SAQUET, métricas inspiradas em Arif et al. (2024) e revisão crítica assistida das questões produzidas.

Leitura principal

A triagem automática não detectou Item-Writing Flaws nas cinco questões. A inspeção do conteúdo, porém, identificou problemas semânticos e linguísticos em quatro itens. Por isso, este relatório não equipara ausência de red flags automáticas a aprovação pedagógica. Uma questão foi classificada como pronta para revisão docente e quatro foram encaminhadas para correção antes de uso.

1. Procedimento de avaliação

Cada item foi analisado em três camadas complementares:

Camada	O que verifica
IWF/SAQUET	19 falhas de construção de itens, combinando regras determinísticas e julgamento semântico automatizado.
Métricas de qualidade	Relevância, gramática, responsabilidade, clareza, especificidade contextual, separação questão-opção, homogeneidade e plausibilidade dos distratores.
Revisão crítica assistida	Coerência conceitual, unicidade do gabarito, idioma, naturalidade dos distratores e adequação para apresentação a docentes.

Síntese da amostra

Item	Tema	IWF	Métricas	Decisão crítica
P01	Transações ACID	0	8/8	Pronta para revisão docente
P02	TCP e UDP	0	8/8	Corrigir
P03	Engenharia de requisitos	0	8/8	Corrigir
P04	Estruturas de dados	0	7/8	Corrigir
P05	Aprendizado supervisionado	0	8/8	Corrigir

A coluna “Métricas” indica quantas das oito dimensões automatizadas receberam parecer positivo. A decisão crítica considera também problemas não capturados automaticamente.

2. Questão P01

PRONTA PARA REVISÃO DOCENTE

Enunciado

Qual propriedade ACID garante que, em caso de falha antes do COMMIT, as alterações parciais não são gravadas no banco?

A	Durabilidade	
B	Consistência	
C	Serialização	
D	Isolamento	
E	Atomicidade	GABARITO

Justificativa gerada

A atomicidade assegura que uma transação é tratada como uma única unidade: se falha antes do COMMIT, todos os efeitos são revertidos, mantendo o banco no estado anterior. Durabilidade protege apenas alterações já confirmadas, portanto não se aplica a falhas ocorridas antes do COMMIT.

Resultado automático

IWF detectados: 0. Classificação automática: acceptable. Dimensões complementares positivas: 8/8.

Revisão crítica assistida

O item apresenta comando claro, gabarito único e distratores pertencentes ao mesmo domínio conceitual. A explicação distingue corretamente atomicidade de durabilidade.

3. Questão P02

[CORRIGIR](#)

Enunciado

Em um cenário de aplicação, compare as garantias de entrega e ordenação oferecidas pelos protocolos de transporte TCP e UDP.

A	Protocolo TCP garante entrega segura e organizado	
B	UDP ensures that data is delivered reliably and in the correct sequence	
C	TCP guarantees reliable, ordered delivery; UDP does not guarantee reliability or order	GABARITO
D	TCP provides guaranteed delivery with acknowledgment for both reliability and ordering	
E	UDP offers a non-reliable service without any assurance of order or packet integrity	

Justificativa gerada

O TCP, por ser orientado à conexão, assegura entrega confiável e ordenada de bytes, controlando fluxo e congestionamento. O UDP, sem conexão, não oferece garantias de entrega nem de ordem, resultando em menor sobrecarga.

Resultado automático

IWF detectados: 0. Classificação automática: acceptable. Dimensões complementares positivas: 8/8.

Revisão crítica assistida

As alternativas misturam português e inglês. A alternativa A contém problemas linguísticos (“segura e organizado”). As alternativas C e D podem ser defendidas como corretas, comprometendo a unicidade do gabarito.

4. Questão P03

[CORRIGIR](#)

Enunciado

Em um sistema de gerenciamento de biblioteca, há um requisito que especifica que os usuários devem poder consultar o catálogo de livros por título ou autor, e a busca deve retornar resultados em até 3 segundos. Qual é a classificação desse requisito?

A	Regulamentos administrativos	
B	Requisitórios políticos	
C	Requisições econômicas	
D	Requisitos estéticos	
E	Requisito funcional	GABARITO

Justificativa gerada

O requisito descreve um serviço que o sistema deve oferecer – a consulta ao catálogo – e define um comportamento esperado, caracterizando um requisito funcional. Requisitos não funcionais, por outro lado, tratam de atributos como desempenho, segurança ou usabilidade, mas não descrevem serviços diretos que o usuário realiza.

Resultado automático

IWF detectados: 0. Classificação automática: acceptable. Dimensões complementares positivas: 8/8.

Revisão crítica assistida

O enunciado reúne uma função do sistema e um limite de desempenho de três segundos, combinando aspectos funcional e não funcional. Distratores como “requisitórios políticos” e “requisitos estéticos” são artificiais e pouco plausíveis.

5. Questão P04

[CORRIGIR](#)

Enunciado

Um serviço de atendimento ao cliente recebe solicitações e as processa na ordem em que chegam, sem necessidade de acesso aleatório aos elementos.

A	Árvore binária de busca	
B	Pilha	
C	Tabela hash	
D	Heap	
E	fila	GABARITO

Justificativa gerada

Para atender solicitações na ordem de chegada, a estrutura que garante a disciplina FIFO e oferece inserção e remoção eficientes é a fila.

Resultado automático

IWF detectados: 0. Classificação automática: acceptable. Dimensões complementares positivas: 7/8.

Revisão crítica assistida

O cenário sugere uma fila, mas não contém uma pergunta ou comando explícito. A formulação deve solicitar diretamente a estrutura adequada e manter alternativas paralelas.

6. Questão P05

[CORRIGIR](#)

Enunciado

Qual característica dos dados permite que o modelo aprenda a prever uma saída específica?

A	dados codificados	
B	informações classificadas	
C	valores marcados	
D	registros etiquetados	
E	exemplos rotulados	GABARITO

Justificativa gerada

Aprendizado supervisionado requer exemplos rotulados que fornecem a saída desejada. Sem esses rótulos, o modelo não pode aprender a prever a saída.

Resultado automático

IWF detectados: 0. Classificação automática: acceptable. Dimensões complementares positivas: 8/8.

Revisão crítica assistida

“Valores marcados”, “registros etiquetados” e “exemplos rotulados” são expressões semanticamente próximas. Há risco de múltiplas respostas defensáveis, apesar de o gabarito registrado ser “exemplos rotulados”.

7. Conclusão

A amostra confirma que as verificações automáticas são úteis como barreira inicial, mas não bastam para aprovar questões educacionais. A divergência entre o resultado automático e a leitura crítica foi especialmente visível em idioma, ambiguidade conceitual e equivalência entre alternativas.

Para apresentação aos professores, recomenda-se usar P01 como exemplo de item pronto para análise docente e P02-P05 como casos que demonstram a função da revisão humana no ciclo da HAILA. Nenhuma questão deve ser aplicada a estudantes sem validação final de especialista.

Referências do procedimento

MOORE, S.; COSTELLO, E.; NGUYEN, H. A.; STAMPER, J. An Automatic Question Usability Evaluation Toolkit. 2024.

ARIF, T.; ASTHANA, S.; COLLINS-THOMPSON, K. Generation and Assessment of Multiple-Choice Questions from Video Transcripts using Large Language Models. Proceedings of L@S 2024. DOI: 10.1145/3657604.3664714.

Nota metodológica: este relatório descreve uma amostra exploratória de cinco itens. Os resultados não sustentam inferência estatística sobre desempenho global da arquitetura.